



Mémoire de projet pratique en R



Conception et implémentation d'un système de prédiction d'AVC

Réalisé par :

Mohamed Lemine Abdallahi Tah

C12896

Mariem Cheikhna Cheikh Mohamed El Mehdi

C14419

Boudah Mohamed Lemine Ahmedou El Mokhtar

C20121

Encadré par :

Dr Aichetou Bouchareb

Membres du jury :

Dr Aichetou Bouchareb

Dr Khalil Elwaled

Année universitaire : 2024 – 2025

Projet réalisé dans le cadre du Master SSD – Statistiques et Sciences des Données

Dédicace

À nos familles,
À nos parents pour leur soutien inconditionnel, leurs prières et
leur amour.

À nos professeurs pour leur encadrement et leur patience.

À tous ceux qui, de près ou de loin, ont contribué à
l'accomplissement de ce projet.

Remerciements

Nous tenons à exprimer nos plus sincères remerciements à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail.

Nos remerciements les plus chaleureux vont à notre encadrante, **Dr Aichetou Bouchareb**, pour son accompagnement, ses conseils avisés et sa disponibilité tout au long de ce projet.

Nous remercions également les membres du jury, **Dr Aichetou Bouchareb** et **Dr Khalil Elwaled**, pour avoir accepté d'évaluer notre travail.

Nous exprimons notre profonde gratitude à l'Université de Nouakchott Al Aasriya, à la Faculté des Sciences et Techniques ainsi qu'à tout le corps enseignant du département de Mathématiques et Informatiques pour la qualité de l'enseignement dispensé.

Enfin, un grand merci à nos familles, amis et collègues pour leur soutien moral, leur encouragement et leur patience.

Table des matières

Introduction Générale	4
1 Bibliothèques et Outils Utilisés	5
1.1 Langage R et environnement de développement	5
1.2 Gestion du projet et développement web	5
2 Prétraitement des Données	6
2.1 Suppression de la variable id	6
2.2 Gestion des valeurs manquantes	6
2.3 Suppression des doublons	7
2.4 Transformation des variables & Séparation des données	7
3 Analyse Exploratoire des Données (EDA)	8
3.1 Visualisation de la variable cible	8
3.2 Analyse univariée	8
3.2.1 Variables continues	9
3.2.2 Variables catégorielles	11
3.3 Analyse bivariée	13
3.4 Corrélation entre variables	18
4 Modélisation & évaluation performances	20
4.1 Données Déséquilibrés :	20
4.1.1 Analyse des résultats des modèles	20
4.2 Application du Cost-Sensitive Learning	21
4.2.1 Résultats avec pondération par classe et normalisation	21
4.2.2 Résultats du modèle régularisé avec ajustement du seuil	22
4.2.3 Arbre de décision avec discrétisation et pondération des classes	22
4.2.4 Réseau de neurones avec normalisation et pondération des classes	23
4.3 Architecture de l'application et persistance des prédictions	24
4.3.1 Architecture	24
4.3.2 Aperçu visuel de l'application	24
Conclusion Générale	27

Introduction Générale

Dans un monde où les maladies cardiovasculaires représentent l'une des principales causes de mortalité, la détection précoce des accidents vasculaires cérébraux (AVC) devient une priorité de santé publique. Grâce à l'avènement de la science des données et de l'apprentissage automatique, il est désormais possible de développer des systèmes intelligents capables d'aider à la prédiction de ces pathologies à partir de données cliniques.

Ce mémoire s'inscrit dans cette dynamique en proposant une approche de prédiction des AVC basée sur des données médicales, en utilisant le langage R, largement reconnu pour sa puissance dans le traitement statistique et la visualisation des données.

L'objectif principal de ce travail est de concevoir et d'implémenter un système de prédiction permettant d'identifier les patients à risque d'AVC, en exploitant un ensemble de variables cliniques. Pour atteindre cet objectif, plusieurs étapes ont été nécessaires, allant du prétraitement des données à la modélisation, en passant par l'analyse exploratoire.

La méthodologie adoptée repose sur l'utilisation d'algorithmes d'apprentissage supervisé, ainsi que sur une analyse statistique approfondie afin d'interpréter les données et d'évaluer la performance des modèles développés.

Ce mémoire est structuré comme suit :

- Le **premier chapitre** est consacré à la présentation des bibliothèques R et des outils utilisés dans le cadre de ce projet.
- Le **deuxième chapitre** traite du prétraitement des données, incluant la gestion des valeurs manquantes et la transformation des variables.
- Le **troisième chapitre** présente l'analyse exploratoire des données (EDA) avec des visualisations pertinentes.
- Le **quatrième chapitre** détaille les différentes méthodes de modélisation et d'évaluation des performances et démonstration de l'application web reliée à l'application .
- Enfin, une conclusion générale résume les résultats obtenus et propose des perspectives d'amélioration.

Chapitre 1

Bibliothèques et Outils Utilisés

Dans le cadre de ce projet, plusieurs bibliothèques et outils ont été utilisés. Ce chapitre présente les principaux éléments technologiques utilisés.

1.1 Langage R et environnement de développement

Le langage **R** est un environnement de programmation dédié à l'analyse statistique et à la visualisation de données. L'environnement **RStudio** a été utilisé pour le développement. Il offre une interface conviviale pour l'écriture, l'exécution du code, ainsi que la gestion des packages et la production de graphiques.



FIGURE 1.1 – Langage R et environnement RStudio

1.2 Gestion du projet et développement web

l'extension **GitHub Copilot** a été utilisée directement dans RStudio. Cet outil propose des suggestions de code intelligentes, ce qui a permis d'accélérer le développement tout en améliorant la qualité du code produit.

Pour la partie interface et interaction avec les utilisateurs, le framework PHP **Laravel** a été choisi. Laravel permet de développer des applications web robustes et évolutives.



FIGURE 1.2 – Outils utilisés : GitHub Copilot et framework Laravel

Chapitre 2

Prétraitement des Données

2.1 Suppression de la variable id

La variable `id`, servant uniquement d'identifiant unique pour chaque observation, a été supprimée. Elle n'apporte aucune information pertinente pour la modélisation prédictive.

Chargement et aperçu du jeu de données

Les données utilisées dans ce projet proviennent du jeu de données `healthcare-dataset-stroke`. Une inspection initiale a permis d'identifier la structure des données et de détecter d'éventuelles anomalies.




FIGURE 2.1 – Visualisation du nombre de valeurs manquantes par variable avant nettoyage (3.9 %) pour `bmi` (Body Mass Index).

2.2 Gestion des valeurs manquantes

Le dataset contenait des valeurs manquantes dans certaines colonnes, notamment dans la variable `bmi`. Celles-ci ont été traitées par suppression des lignes incomplètes afin d'assurer la

fiabilité de l'analyse.




FIGURE 2.2 – Visualisation du nombre de valeurs manquantes par variable après nettoyage.

Le jeu de données comportait initialement **5110** observations. Après suppression des lignes contenant des valeurs manquantes (principalement associées à la variable `bmi`), le nombre total d'observations est réduit à **4909**.

2.3 Suppression des doublons

Une vérification de la présence de doublons a été effectuée. Cette opération a indiqué qu'**aucun doublon** n'était présent dans le jeu de données.

```
58 stroke_data_clean <- stroke_data %>% drop_na() %>% distinct()
59 n_duplicates <- nrow(stroke_data_clean) - nrow(distinct(stroke_data_clean))
60 rows_after <- nrow(stroke_data_clean)
61
62 cat(" Lignes avant nettoyage:", rows_before, "\n")
63 cat(" Lignes après nettoyage:", rows_after, "\n")
64 cat(" Doublons supprimés:", n_duplicates, "\n")
65
66
```

58:1 (Untitled) : Copilot: No completions available

Console Terminal Background Jobs

R 4.5.0 ~/StrokePrediction/

```
> cat(" Lignes avant nettoyage:", rows_before, "\n")
Lignes avant nettoyage: 5110
> cat(" Lignes après nettoyage:", rows_after, "\n")
Lignes après nettoyage: 4909
> cat(" Doublons supprimés:", n_duplicates, "\n")
Doublons supprimés: 0
```

FIGURE 2.3 – Résultat de la suppression des doublons : aucun doublon détecté.

2.4 Transformation des variables & Séparation des données

Certaines variables catégorielles (`gender`, `ever_married`, etc.) ont été converties en facteurs. Une normalisation a également été appliquée sur les variables continues afin de faciliter l'apprentissage des modèles.

Enfin, les données ont été divisées en deux sous-ensembles :

- **80%** pour l'entraînement,
- **20%** pour le test,

Chapitre 3

Analyse Exploratoire des Données (EDA)

Ce chapitre est consacré à l'analyse exploratoire des données, afin de mieux comprendre les variables du jeu de données et leurs relations avec la variable cible `stroke`.

3.1 Visualisation de la variable cible

Nous commençons par examiner la distribution de la variable cible `stroke`, qui est fortement déséquilibrée. Très peu de patients dans l'échantillon ont subi un AVC 209/4909 (4.3%).




FIGURE 3.1 – Distribution de la variable cible `stroke`

3.2 Analyse univariée

L'analyse univariée permet d'étudier séparément chaque variable pour comprendre ses caractéristiques principales.

3.2.1 Variables continues

Analyse des variables continues

La figure 3.2 présente la distribution des principales variables continues du jeu de données, notamment `age`, `avg_glucose_level`, `bmi`, `heart_disease` et `hypertension`.

- **Age** : la distribution de l'âge est relativement uniforme entre 0 et 80 ans, avec une légère concentration autour de 50 à 60 ans.
- **Avg Glucose Level** : la distribution du taux moyen de glucose est asymétrique à droite, indiquant la présence de quelques valeurs élevées (hyperglycémie).
- **BMI** : l'indice de masse corporelle suit une distribution légèrement asymétrique à droite, centrée autour de 25 à 30, ce qui suggère un taux modéré de surpoids parmi les individus.

Ces observations permettent d'anticiper l'importance de certaines variables dans l'analyse prédictive du risque d'AVC.




FIGURE 3.2 – Distribution des variables continues

Boîtes à moustaches




FIGURE 3.3 – Boîte à moustaches des variables continues du jeu de données

les distributions des variables continues `age`, `avg_glucose_level` et `bmi` à l'aide de boîtes à moustaches. Ces graphiques permettent d'observer la dispersion des données, la médiane, ainsi que la présence de valeurs aberrantes (*outliers*).

- **Age** : la médiane se situe autour de 50 ans. La distribution est assez symétrique et concentrée, avec peu de valeurs aberrantes, indiquant une population relativement homogène en termes d'âge.
- **Avg_glucose_level** : cette variable présente une forte asymétrie à droite, avec un grand nombre de valeurs aberrantes supérieures à 200 mg/dL. Cela peut indiquer la présence de cas de diabète sévère ou de dysrégulation glycémique dans l'échantillon.
- **BMI** : la médiane est proche de 28, ce qui suggère une tendance au surpoids dans la population. Quelques valeurs extrêmes sont visibles, bien qu'en nombre plus restreint que pour la glycémie.

Ces observations permettent de mieux comprendre la nature des données continues et mettent en évidence la nécessité d'un traitement particulier pour les variables fortement asymétriques ou contenant de nombreux outliers.

3.2.2 Variables catégorielles



FIGURE 3.4 – Distribution des variables catégorielles dans le jeu de données utilisé pour l'étude de l'AVC.

Le graphique présente la distribution des principales variables catégorielles. Voici quelques observations clés :

- **Genre** : La majorité des individus sont de sexe féminin (59%).
- **État matrimonial** : 65.3% des personnes ont déjà été mariées.
- **Hypertension et maladies cardiaques** : Seulement 9.2% souffrent d'hypertension et 5% ont une maladie cardiaque.

- **Type de résidence** : Répartition quasi égale entre milieux rural (49.3%) et urbain (50.7%).
- **Statut tabagique** : La catégorie « jamais fumé » domine (37.7%), mais 30.2% ont un statut de tabagisme inconnu.
- **Type de travail** : Plus de la moitié (57.3%) sont des employés du secteur privé.
- **Accidents vasculaires cérébraux (AVC)** : Seulement 4.3% ont subi un AVC, ce qui peut refléter la rareté relative de cette condition dans l'échantillon.

3.3 Analyse bivariée

Cette partie explore les relations entre les variables et la variable cible `stroke`.

Comparaison des variables avec la cible




FIGURE 3.5 – Distribution de l'âge selon la présence d'un AVC

Commentaire : On observe que les cas d'AVC sont rares chez les jeunes patients et deviennent de plus en plus fréquents avec l'âge. La majorité des AVC se produisent chez les patients âgés de plus de 60 ans, ce qui confirme que l'âge est un facteur de risque majeur pour les accidents vasculaires cérébraux.




FIGURE 3.6 – Répartition de l'hypertension selon l'occurrence d'un AVC

Commentaire : la répartition des cas d'AVC en fonction de la variable *hypertension*. On observe que chez les individus hypertendus, 13,3 % ont été victimes d'un AVC, contre seulement 3,3 % chez ceux qui ne souffrent pas d'hypertension. Cette différence suggère une association positive entre l'hypertension et la survenue d'un AVC, ce qui est cohérent avec les connaissances médicales établies. Ainsi, l'hypertension semble constituer un facteur de risque significatif d'AVC dans ce jeu de données.




FIGURE 3.7 – Répartition du statut tabagique selon l'occurrence d'un AVC

Commentaire : la distribution des cas d'AVC selon le statut tabagique des individus. On observe que la proportion d'AVC varie modérément selon le profil tabagique. Les anciens fumeurs présentent le taux d'AVC le plus élevé (6,8 %), suivis des fumeurs actuels (5,3 %) et des personnes n'ayant jamais fumé (4,5 %). La catégorie "Unknown" affiche un taux d'AVC plus faible (2 %), probablement en raison d'une taille d'échantillon plus réduite ou d'un biais de non-réponse. Bien que le tabagisme soit reconnu comme un facteur de risque cardiovasculaire, les différences observées ici restent relativement faibles par rapport à d'autres facteurs comme l'hypertension ou les maladies cardiaques.




FIGURE 3.8 – Répartition selon le type de résidence et l'AVC

Commentaire : la répartition des cas d'AVC selon que les individus vivent en zone rurale ou urbaine. Les pourcentages d'AVC sont relativement similaires dans les deux environnements : 4,1 % pour les habitants en milieu rural contre 4,4 % en milieu urbain. Cette faible différence suggère que Le type de résidence ne semble donc pas avoir une influence majeure sur l'occurrence d'un AVC dans cet échantillon.




FIGURE 3.9 – Répartition selon le type de travail et l'AVC

Commentaire : la répartition des cas d'AVC en fonction du type d'activité professionnelle. On observe que les enfants (*children*) et les personnes n'ayant jamais travaillé (*Never worked*) affichent des taux d'AVC extrêmement faibles voire nuls, respectivement 0,1 % et 0 %. Les travailleurs du secteur public (*Govt_job*) et du secteur privé (*Private*) ont des taux d'AVC similaires, respectivement 4,4 % et 4,5 %. En revanche, les individus exerçant une activité indépendante (*Self-employed*) présentent un taux plus élevé, atteignant 6,8 %. Ces résultats suggèrent que certaines conditions de travail, en particulier l'auto-emploi, pourraient être associées à un risque accru d'AVC, possiblement en lien avec le stress ou l'absence de couverture sociale.




FIGURE 3.10 – Répartition selon le statut marital et l'AVC

Commentaire : la répartition des cas d'AVC selon que les individus aient déjà été mariés ou non. Il apparaît que les personnes ayant été mariées (*Yes*) présentent un taux d'AVC plus élevé (5,8 %) comparé à celles n'ayant jamais été mariées (*No*), dont le taux est de seulement 1,3 %. Cette différence pourrait s'expliquer par des facteurs liés à l'âge, puisque les personnes mariées sont en général plus âgées, et donc potentiellement plus exposées aux risques d'AVC.




FIGURE 3.11 – Répartition des cas d’AVC selon la présence de maladies cardiaques

La Figure met en évidence une nette différence dans la proportion d’AVC entre les individus atteints ou non de maladies cardiaques. Parmi ceux qui souffrent de maladies cardiaques, 16,5 % ont été victimes d’un AVC, contre seulement 3,6 % chez les individus ne présentant pas de pathologie cardiaque. Cette observation suggère que la présence de maladies cardiaques constitue un facteur aggravant du risque d’AVC. Ce résultat est cohérent avec la littérature médicale, qui établit un lien entre les affections cardiovasculaires et les événements cérébrovasculaires.




FIGURE 3.12 – Distribution du taux moyen de glucose selon la présence d’un AVC

Commentaire : la distribution du taux de glucose pour deux groupes : les individus ayant subi un AVC (en rouge) et ceux n’en ayant pas subi (en bleu). On observe que la majorité des cas, quelle que soit la présence d’un AVC, se concentre dans les classes de taux de glucose comprises entre 80 et 140. Les individus ayant subi un AVC sont nettement moins nombreux, mais leur répartition semble suivre une tendance similaire à celle des non-AVC. Cela peut suggérer que, bien qu’un taux de glucose élevé soit souvent observé chez les personnes ayant eu un AVC, ce facteur à lui seul ne permet pas de différencier clairement les deux populations.




FIGURE 3.13 – Distribution du BMI selon la présence d'un AVC

Commentaire : la distribution de l'indice de masse corporelle (BMI) en distinguant les individus ayant subi un AVC (en rouge) de ceux n'en ayant pas subi (en bleu). On remarque que la majorité des cas (avec ou sans AVC) se situe dans une plage d'IMC comprise entre 20 et 40, avec un pic autour de 28. Les cas d'AVC apparaissent relativement plus fréquents dans cette zone centrale, mais la différence n'est pas très marquée visuellement. Cela indique que, bien que l'IMC soit un facteur de risque reconnu pour AVC, mais sa répartition ne permet pas ici de distinguer clairement les individus selon leur statut AVC.




FIGURE 3.14 – Répartition selon le genre et la présence d'un AVC

Commentaire : la répartition des cas d'AVC en fonction du genre. On observe que la proportion de cas d'AVC est similaire entre les femmes (4,1 %) et les hommes (4,4 %). Toutefois, une légère prédominance féminine est visible parmi les cas d'AVC. Cela pourrait s'expliquer par des facteurs biologiques ou sociaux influençant la santé cardiovasculaire. En revanche, la catégorie *Other* affiche une proportion de 0 % de cas d'AVC. Il est important de noter que cette dernière catégorie ne contient qu'un seul individu dans l'ensemble de données.

3.4 Corrélation entre variables

Matrice de corrélation entre les variables continues




FIGURE 3.15 – Matrice de corrélation des variables numériques.

Commentaire : La matrice de corrélation entre les variables continues de l'étude. On observe une corrélation positive modérée entre l'âge et l'IMC (*bmi*) avec un coefficient de 0,33, ce qui indique que l'IMC tend à augmenter légèrement avec l'âge. L'âge et le taux moyen de glucose (*avg_glucose_level*) présentent également une corrélation positive plus faible (0,24). Enfin, la corrélation entre le glucose moyen et l'IMC est relativement faible (0,18), suggérant une relation limitée entre ces deux variables. Globalement, aucune des corrélations n'est suffisamment forte pour indiquer une colinéarité problématique entre les variables.

TABLE 3.1 – Matrice de corrélation entre les variables continues

	age	avg_glucose_level	bmi
age	1.000	0.236	0.333
avg_glucose_level	0.236	1.000	0.176
bmi	0.333	0.176	1.000




FIGURE 3.16 – Nuage de points entre l'âge et l'IMC, coloré par le statut d'AVC

Commentaire sur le nuage de points Âge - IMC et Statut AVC : la relation entre l'âge et l'indice de masse corporelle (IMC) des individus. On observe une légère tendance ascendante, indiquant une corrélation positive modérée entre les deux variables. Cela suggère que l'IMC tend à augmenter avec l'âge, bien que la dispersion des points révèle une variabilité importante, notamment chez les personnes âgées. Cette observation est cohérente avec le coefficient de corrélation de 0,33 obtenu précédemment, qui traduit une association modérée mais non linéaire entre ces deux variables continues.

Chapitre 4

Modélisation & évaluation performances

4.1 Données Déséquilibrés :

4.1.1 Analyse des résultats des modèles

Quatre algorithmes de classification ont été testés sur notre jeu de données : la régression logistique, l'arbre de décision, la forêt aléatoire (Random Forest) et le classifieur de Naive Bayes. Les résultats obtenus, bien que montrant une précision (*accuracy*) relativement élevée de 95.82%, révèlent en réalité une faiblesse critique commune à tous les modèles : ils prédisent uniquement la classe majoritaire (**No Stroke**) et ignorent totalement la classe minoritaire (**Stroke**).

TABLE 4.1 – Résumé des matrices de confusion pour les différents modèles

Modèle	Prédiction	No Stroke	Stroke	Total Prédits
Régression Logistique	No Stroke	940	41	981
	Stroke	0	0	0
Arbre de Décision	No Stroke	940	41	981
	Stroke	0	0	0
Random Forest	No Stroke	940	41	981
	Stroke	0	0	0
Naive Bayes	No Stroke	940	41	981
	Stroke	0	0	0

Ces résultats indiquent que les modèles sont biaisés en faveur de la classe dominante et ne sont donc pas adaptés à la détection des cas de **Stroke**, qui représentent pourtant la cible d'intérêt principale de cette étude. Ce phénomène est typique des problèmes de classification déséquilibrée, où la classe minoritaire est ignorée par les algorithmes standards.

Cette étape met en évidence la nécessité de traiter le déséquilibre du jeu de données avant toute tentative de modélisation fiable.

4.2 Application du Cost-Sensitive Learning

Pour améliorer la détection de la classe minoritaire (*Stroke*), nous avons appliqué une approche **Cost-Sensitive Learning** en utilisant une matrice de coût asymétrique :

```
cost_matrix <- matrix(c(0, 1, 5, 0), nrow = 2,
                      dimnames = list(predicted = c("No Stroke", "Stroke"),
                                      actual = c("No Stroke", "Stroke")))
```

Résultats des modèles

Modèle	Accuracy	Sensitivity	Specificity	F1 Score	AUC
Régression Logistique	93.27%	96.06%	29.27%	0.27	0.63
Random Forest	95.82%	100%	0%		0.50
KNN	95.21%	99.25%	2.44%	0.04	0.51

TABLE 4.2 – Performances des modèles avec Cost-Sensitive Learning

L'entraînement a été réalisé avec une validation croisée afin d'optimiser les hyperparamètres.

4.2.1 Résultats avec pondération par classe et normalisation

Dans cette seconde phase, nous avons appliqué un apprentissage sensible au coût à travers des **poids de classe**, tout en **normalisant les variables continues**. Les poids ont été définis pour renforcer l'impact des exemples positifs (cas d'AVC), selon la règle suivante :

```
class_weights <- ifelse(train_data$stroke == "Stroke", 10, 1)
```

L'entraînement a été réalisé avec une validation croisée afin d'optimiser les hyperparamètres.

Modèle	Accuracy	Sensitivity	Specificity	F1 Score	ROC-AUC
Régression Logistique	84.71%	58.54%	85.85%	0.15	0.846
Random Forest	95.72%	2.44%	99.79%	0.33	0.798
KNN	95.82%	0.00%	100.00%	NaN	0.711

TABLE 4.3 – Performances des modèles avec pondération par classe et normalisation

Analyse comparative

- Le modèle de régression logistique a montré le meilleur compromis entre sensibilité et spécificité, avec un **ROC-AUC de 0.85**.
- Le Random Forest reste biaisé malgré l'intégration des poids, n'identifiant qu'un seul cas d'AVC.
- Le KNN n'a identifié aucun cas positif, ce qui confirme sa faiblesse sur des classes déséquilibrées même après pondération.

4.2.2 Résultats du modèle régularisé avec ajustement du seuil

Afin d'améliorer la détection de la classe minoritaire, nous avons ajusté le seuil de classification du modèle GLMNET de 0.5 à 0.3. Cette modification permet de favoriser la prédiction de la classe *Stroke*.

Statistiques de performance (seuil = 0.3)

Accuracy	Sensitivity	Specificity	F1 Score
70.95%	85.37%	70.32%	0.11

TABLE 4.4 – Model Performance Metrics

Cette stratégie de changement de seuil améliore considérablement la sensibilité (capacité à détecter les AVC) au détriment de la précision globale. Le modèle détecte 35 vrais cas d'AVC .

Matrice de confusion




FIGURE 4.1 – Matrice de confusion du modèle GLMNET avec seuil ajusté à 0.3

4.2.3 Arbre de décision avec discrétisation et pondération des classes

Nous avons testé un arbre de décision en appliquant une **discrétisation des variables continues** en 10 intervalles d'amplitude égale. De plus, un apprentissage sensible au coût a été mis en place via une pondération plus forte pour la classe minoritaire : **Cost-Sensitive Learning : Stroke x10 , No Stroke x 1** L'entraînement s'est appuyé sur une validation croisée à 5 plis.

Accuracy	Sensitivity	Specificity	F1 Score
84.81%	53.66%	86.17%	0.145

TABLE 4.5 – Model Performance Metrics

Ce modèle parvient à identifier une proportion modérée de cas positifs (AVC), avec un compromis acceptable entre précision globale et sensibilité. L'approche de discrétisation permet de rendre les décisions plus compréhensibles dans un contexte médical.

4.2.4 Réseau de neurones avec normalisation et pondération des classes

Un réseau de neurones a été entraîné après avoir **normalisé les variables continues** dans l'intervalle $[0,1]$:

```
normalize <- function(x) (x - min(x)) / (max(x) - min(x))
```

Les variables `age`, `bmi` et `avg_glucose_level` ont été transformées en `age_norm`, `bmi_norm`, `glucose_norm`, et les colonnes originales ont été supprimées.

Des poids de classe ont été calculés dynamiquement en fonction des effectifs avec un **facteur multiplicatif de 1.5**, pour renforcer l'apprentissage sensible au coût.

L'entraînement a été réalisé avec une **validation croisée à 5 plis** et une **recherche d'hyperparamètres** sur deux dimensions :

- `size` (nombre de neurones cachés) : $\{5, 10, 15, 20\}$
- `decay` (taux de régularisation) : $\{0.001, 0.01, 0.1, 0.15\}$

Résultats du modèle

Accuracy	Sensitivity	Specificity	F1 Score	Balanced Accuracy
76.25%	87.80%	75.75%	0.14	0.8178

TABLE 4.6 – Model Performance Metrics

Ce modèle atteint l'une des meilleures sensibilités parmi tous ceux testés, ce qui le rend pertinent dans un contexte de dépistage médical, malgré une précision générale plus modeste.

Matrice de confusion du réseau de neurones avec pondération (seuil par défaut)




FIGURE 4.2 – Matrice de confusion du réseau de neurones avec normalisation et pondération (seuil par défaut)

4.3 Architecture de l'application et persistances des prédictions

Présentation générale


Cette section détaille l'architecture logicielle de l'application **AVC-Predict** basée sur Laravel (PHP) et la structure de la base de données MySQL utilisée pour stocker les données des utilisateurs et les résultats de prédiction.

4.3.1 Architecture

Frontend & Backend : L'application utilise Laravel pour gérer les routes, les contrôleurs et l'accès à la base de données.

Appel au modèle R : Après soumission, les données sont envoyées à un modèle de réseau de neurones implémenté en R, via un script ou une API interne. **Réponse et stockage :** Le résultat de prédiction (AVC / Non AVC) est retourné et affiché, puis enregistré dans la base de données pour un usage ultérieur.

4.3.2 Aperçu visuel de l'application



The screenshot displays the 'AVC-Predict' web application interface. On the left is a dark sidebar with navigation links: 'Home', 'Bienvenue', 'Statistiques', 'Prédiction AVC' (highlighted), 'Tableau de bord', 'Analysis', 'Contact', and 'À propos'. The main content area is titled 'Remplissez les informations du patient' and contains a form with the following fields:


- Nom complet:** Text input with 'John Doe'.
- Email:** Text input with 'john@example.com'.
- Téléphone:** Text input with '22332233'.
- Genre:** Dropdown menu with 'Male' selected.
- Hypertension:** Dropdown menu with 'Yes' selected.
- Maladie cardiaque:** Dropdown menu with 'Yes' selected.
- Déjà marié(e):** Dropdown menu with 'Yes' selected.
- Type d'emploi:** Dropdown menu with 'Private' selected.
- Type de résidence:** Dropdown menu with 'Urban' selected.
- Statut tabagique:** Dropdown menu with 'never smoked' selected.
- Âge:** Text input with '79'.
- IMC:** Text input with '35'.
- Glucose moyen:** Text input with '188'.

At the bottom right of the form is a blue button labeled 'Prédire AVC'. The footer of the page includes the copyright notice 'Copyright © 2014-2021 AdminLTE.io. All rights reserved.' and the version number 'Version 3.2.0'.

L'application **AVC-Predict** propose une interface intuitive permettant aux utilisateurs de soumettre leurs informations cliniques et démographiques dans un **formulaire de prédiction**.

L'utilisateur saisit son nom, email, (téléphone optionnel), ainsi que des variables médicales telles que l'âge, l'IMC, le taux de glucose, le genre, la présence d'hypertension ou de maladies cardiaques, le statut marital, le type de travail, la zone de résidence et le statut tabagique. Une fois le formulaire validé, les données sont envoyées au backend Laravel, qui appelle un

modèle R de prédiction (réseau de neurones pondéré). Le résultat est ensuite renvoyé et **affiché dynamiquement** dans une nouvelle section.




The screenshot shows a web browser at the address 127.0.0.1:8000/predict. The application has a dark sidebar with navigation links: Accueil, Statistiques, Prédiction AVC, Tableau de bord, Analysis, Contact, and À propos. The main content area is titled 'Résultat de la prédiction : AVC' and displays a table of user information and prediction results.

Nom	John Doe
Email	john@example.com
Téléphone	22332233
Genre	Male
Hypertension	Yes
Maladie cardiaque	Yes
Déjà marié(e)	Yes
Type d'emploi	Private
Résidence	Urban
Tabagisme	never smoked
Âge	79
IMC	35
Glucose	188

Copyright © 2014-2021 AdminLTE.io. All rights reserved. Version 3.2.0

Une fois la prédiction réalisée, toutes les informations saisies par l'utilisateur, ainsi que le résultat du modèle (**Stroke** ou **No Stroke**), sont **stockées automatiquement** dans la base de données MySQL (*stroke_{prediction}*).



The screenshot shows a MySQL database interface with the 'predictions' table selected. The table contains 5 rows of data. The query shown is 'SELECT * FROM `predictions` ORDER BY created_at DESC LIMIT 5;'. The table structure is as follows:

	id	name	email	phone	gender	hypertension	heart_disease	ever_married	work_type	Residence_type	smoking_status	age	bmi	glucose	result	created_at	updated_at
☐	51	John Doe	eric@example.com	22332231	Male	Yes	Yes	Yes	Private	Urban	unknown	69	35	90	1	2025-06-16 13:28:41	2025-06-16 13:28:45
☐	50	John Doe	john@example.com	22332232	Male	Yes	Yes	Yes	Govt_job	Rural	smoked	79	35	188	1	2025-06-16 13:28:17	2025-06-16 13:28:21
☐	49	John Doe	mark@example.com	22332234	Male	Yes	Yes	Yes	Private	Urban	never smoked	79	35	89	1	2025-06-16 13:22:58	2025-06-16 13:23:02
☐	48	John Doe	erni@example.com	22332233	Female	Yes	No	No	Self-employed	Rural	never smoked	37	35	77	0	2025-06-16 13:14:34	2025-06-16 13:14:34
☐	47	John Doe	john@example.com	22332235	Male	Yes	Yes	Yes	Private	Urban	never smoked	79	35	188	1	2025-06-16 13:13:19	2025-06-16 13:13:23

FIGURE 4.3 – Structure de la base de données contenant les prédictions

L'application inclut également une page dédiée aux statistiques générales des prédictions collectées, offrant une visualisation synthétique de la répartition des résultats.




FIGURE 4.4 – Page de statistiques globales (analyse exploratoire)

Enfin, une page « À propos » est accessible pour expliquer le contexte du projet, la finalité de l'application, les technologies utilisées, ainsi que des informations sur les auteurs du système.




FIGURE 4.5 – Page « À propos » de l'application

Cette architecture permet un cycle complet de collecte, prédiction et amélioration itérative du modèle, exploitant pleinement Laravel pour l'interface et MySQL pour la persistance des données cliniques.

Conclusion Générale

nous avons conçu et implémenté un système de prédiction des accidents vasculaires cérébraux (AVC) basé sur des données cliniques, en combinant les techniques de la science des données avec des outils de développement web. Le processus a couvert toutes les étapes du cycle de vie d'un projet de data science, du prétraitement des données jusqu'à l'intégration d'un modèle de machine learning dans une application web fonctionnelle.

L'analyse exploratoire a révélé une forte déséquilibre des classes, ce qui a nécessité l'emploi de méthodes spécifiques comme le *Cost-Sensitive Learning*, la pondération des classes, la normalisation et l'ajustement du seuil de classification. Ces techniques ont permis d'améliorer significativement la sensibilité des modèles vis-à-vis de la classe minoritaire (Stroke), tout en maintenant une précision globale raisonnable.

Parmi les modèles testés, le réseau de neurones normalisé et pondéré a offert le meilleur compromis.

Parallèlement, l'application web AVC-Predict développée avec Laravel et MySQL permet à la fois l'interface de saisie, l'invocation du modèle de prédiction via R, l'affichage des résultats, ainsi que la conservation des prédictions pour une analyse ultérieure.

En conclusion, ce projet démontre la pertinence de data-sciences dans la prévention des AVC et ouvre la voie à des applications concrètes en santé publique assistée par l'intelligence artificielle.